

Diese Übungen sollen am **28. Jänner 2020** in den Übungsgruppen vorgestellt werden. Die Aufgaben, die Sie bereit sind in den Übungen an der Tafel zu präsentieren, müssen in TUWEL bis zum **27. Jänner 2020 um 23:30 Uhr** angekreuzt werden.

(1) **Kovarianz**

Es seien X, Y und Z Zufallsvariable mit endlicher Varianz und $a, b \in \mathbb{R}$ konstant. Die Kovarianz von X und Y ist gegeben durch $\text{Cov}(X, Y) := \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])]$. Zeigen Sie

- (a) $\text{Cov}(X, Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$
- (b) $\text{Cov}(X, Y) = \text{Cov}(Y, X)$ (Symmetrie)
- (c) $\text{Cov}(X, X) = \text{Var}(X)$
- (d) $\text{Cov}(X, a) = 0$
- (e) $\text{Cov}(aX + bZ, Y) = a\text{Cov}(X, Y) + b\text{Cov}(Z, Y)$ (Linearität)
- (f) Gilt die Linearität auch für die zweite Komponente?
- (g) $\text{Var}(X + Y) = \text{Var}(X) + \text{Var}(Y) + 2\text{Cov}(X, Y)$
- (h) Falls X und Y unabhängig, so ist $\text{Cov}(X, Y) = 0$. (Tipp: Hier dürfen Sie nutzen, dass für X und Y unabhängig gilt, dass $\mathbb{E}[XY] = \mathbb{E}[X]\mathbb{E}[Y]$.)

(2) **Korrelation (Teil 1)**

Es seien X und Y Zufallsvariable mit $\text{Var}(X), \text{Var}(Y) \in (0, \infty)$. Dann ist deren Korrelation gegeben durch

$$\text{Corr}(X, Y) := \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)} \cdot \sqrt{\text{Var}(Y)}}.$$

- (a) Es seien X und Z unkorrelierte Zufallsvariable mit $\text{Var}(X) = \text{Var}(Z) = 1$, und es sei $k \in [-1, 1]$. Was ist die Korrelation von X und $Y := kX + \sqrt{1 - k^2}Z$?
Wir bemerken, dass Y linear von X (und linear von Z) abhängt.
- (b) Für X gelte $\mathbb{E}[X] = \mu_x$ und $\text{Var}(X) = \sigma_x^2$. Konstruieren Sie in Anlehnung an Teil (a) eine Zufallsvariable Y , welche ebenfalls linear von X und linear von Z abhängt, aber vorgegebenes $\mu_y := \mathbb{E}[Y] \in \mathbb{R}$, $\sigma_y^2 := \text{Var}(Y) > 0$ und $\rho := \text{Corr}(X, Y) \in [-1, 1]$ besitzt. Tipp: Standardisieren Sie X .
- (c) Da Y aus (b) linear von X und linear von Z abhängt, ist es von der Form $Y = \beta_0 + \beta_1 X + \sigma Z$. Zeigen Sie, dass

$$\beta_1 = \rho \cdot \frac{\sigma_y}{\sigma_x} \quad \text{und} \quad \beta_0 = \mu_y - \beta_1 \mu_x,$$

und dass sich σ durch ρ und σ_y ausdrücken lässt.

(3) **Korrelation (Teil 2)**

Es seien $X \sim N(3, 1)$ und $Y \sim N(2, 4)$. Plotten Sie 100 Realisierungen von (X, Y) (y_i gegen x_i aufgetragen, $i = 1, \dots, 100$) wobei

- (a) $\text{Corr}(X, Y) = 0$
- (b) $\text{Corr}(X, Y) = 0.8$
- (c) $\text{Corr}(X, Y) = -0.5$
- (d) $\text{Corr}(X, Y) = -1$

Fügen Sie zudem Geraden der Form $\{(x, y) \in \mathbb{R}^2 | y = \beta_0 + \beta_1 x\}$ mit β_0 und β_1 gemäß Aufgabe 2 Teil c ein. Berechnen Sie jeweils die empirische Korrelation r der Realisierungen und fügen Sie diese den plots bei.

(4) **Korrelation (Teil 3)**

Es sei $X \sim N(\mu_x, \sigma_x^2)$.

- (a) Was ist die Korrelation von X und $Y := (X - \mu_x)^2$? (Tipp: Nutzen Sie, dass bei der Normalverteilung die ungeraden zentrierten Momente verschwinden, d.h., $\mathbb{E}[(X - \mathbb{E}[X])^k] = 0$ für $k = 1, 3, 5, \dots$)
- (b) Es sei $\mu_x = 2$ und $\sigma_x^2 = 4$. Generieren Sie 100 Realisierungen $(x_i)_{i=1, \dots, 100}$ von X und plotten Sie sämtliche $y_i = (x_i - \mu_x)^2$ gegen x_i . Geben Sie die empirische Korrelation r der $(x_i)_i$ und $(y_i)_i$ an. Passt ihr Ergebnis zu Teil (a)?
- (c) Fügen Sie zudem die Gerade der Form $\{(x, y) \in \mathbb{R}^2 | y = \beta_0 + \beta_1 x\}$ mit β_0 und β_1 gemäß Aufgabe 2 Teil c ein. Würden Sie sagen, dass die Unkorreliertheit die Unabhängigkeit impliziert? Was misst die Korrelation? Ergibt es Sinn diese Gerade hier einzuzichnen?

(5) **Regression (Teil 1)**

Eine Vorlesung wurde evaluiert. In der Datei `Evaluation.Rdata` finden Sie Daten von $n = 25$ Studierenden. Erfasst wurden erstens, die in den angegliederten Übungen erzielten Übungspunkte (zwischen 0 und 200 möglich), und zweitens das Klausurergebnis (in %). Lässt sich das Klausurergebnis durch die erzielten Übungspunkte erklären?

- (a) Plotten Sie die Klausurergebnisse (y_i) gegen die Übungspunkte (x_i) . Erkennen Sie einen Zusammenhang?
- (b) Berechnen Sie den y -Achsenabschnitt b_0 und die Steigung b_1 der Regressionsgeraden (ohne `lm()`) und zeichnen Sie Letztere ein. Kommentieren Sie die Bedeutung der Steigung.
- (c) Würden Sie sagen, dass der Zusammenhang kausal ist? Das heißt, dass z.B. viele Übungspunkte der Grund für gutes Abschneiden in der Klausur sind?

(6) **Regression (Teil 2)**

Fortsetzung von Aufgabe 5: Nehmen Sie das lineare Regressionsmodell $Y_i = \beta_0 + \beta_1 x_i + \sigma Z_i$ ($i = 1, \dots, n$) an, mit Z_1, \dots, Z_n unabhängig und identisch verteilt und $Z_1 \sim N(0, 1)$, und testen Sie die Nullhypothese $H_0 : \beta_1 = 0$ (ohne `lm()`) zum Signifikanzniveau von 5%. Berechnen Sie dafür

- (a) den Standardfehler der Regression,
- (b) den Standardfehler von β_1 ,
- (c) den Wert der t -Statistik,
- (d) die mit H_0 assoziierte t -Verteilung,
- (e) und den P -Wert.
- (f) Formulieren Sie ein Ergebnis.

(7) **Regression (Teil 3)**

Führen Sie die Analyse aus Aufgabe 6 nun mit Hilfe des Befehls `lm()` durch.

- (a) Passen Sie die Daten mit Hilfe des Befehls `lm()` an das Modell an. Lesen Sie den Ausgang des Tests der Nullhypothese $H_0 : \beta_1 = 0$ aus der Ausgabe von `summary()` ab.
- (b) Plotten Sie (erneut) die Datenpunkte und die Regressionsgerade und diskutieren Sie, inwieweit die Modellannahmen plausibel sind.
- (c) Welches Klausurergebnis prognostizieren Sie Studierenden, die 140 Übungspunkte erhalten haben? Markieren Sie die Prognose in der Grafik.
- (d) Mit welchem Fehler müssen Sie bei der Prognose rechnen? Fügen Sie der Grafik zwei Geraden hinzu, welche parallel der Regressionsgeraden verlaufen, aber deren y -Achsenabschnitt dem der Regressionsgeraden um einen Standardfehler der Regression erhöht bzw. erniedrigt ist.